

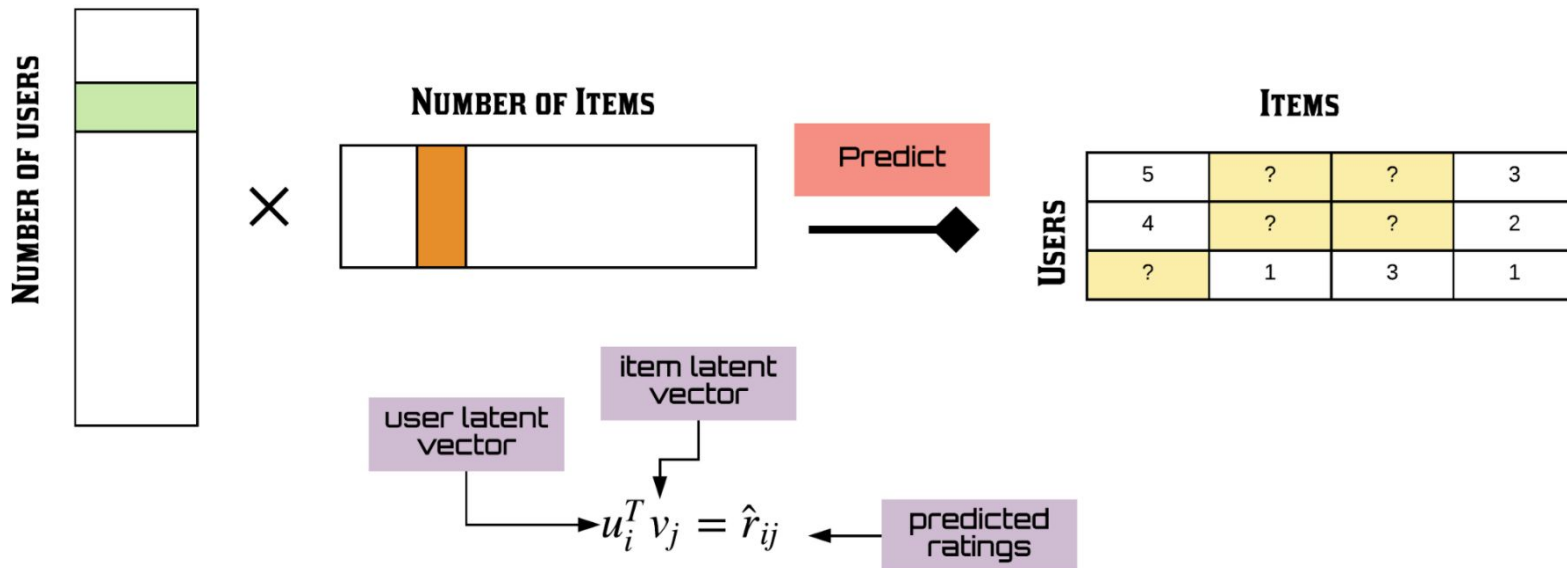
Matris Ayrıştırma

Kamer Kaya
Sabancı Üniversitesi

Yapay Öğrenme için Matematik, 1-6 Şubat 2021, Nesin Matematik Köyü

Sabancı
Üniversitesi

Matris Ayırıştırma





Determinant


$$\det(\mathbf{A}) = \begin{vmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{vmatrix}$$

Tanım: Bir **kare** matrisin **determinantı**, o matrisi bir sayıya eşleyen bir fonksiyondur.

$$\det(\mathbf{A}) = \det(a_{11}) = a_{11} \quad (n = 1)$$

$$\begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11}a_{22} - a_{12}a_{21} \quad (n = 2)$$

$$\begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = a_{11}a_{22}a_{33} + a_{21}a_{32}a_{13} + a_{31}a_{12}a_{23} \\ - a_{31}a_{22}a_{13} - a_{11}a_{32}a_{23} - a_{21}a_{12}a_{33} \quad (n = 3)$$





Determinant

Teorem: Bir kare matris $\mathbf{A} \in \mathbb{R}^{n \times n}$ 'in tersi ancak ve ancak $\det(\mathbf{A}) \neq 0$ ise vardır.

2×2 bir \mathbf{A} matrisi için

$$\mathbf{A}^{-1} = \frac{1}{a_{11}a_{22} - a_{12}a_{21}} \begin{bmatrix} a_{22} & -a_{12} \\ -a_{21} & a_{11} \end{bmatrix}$$

$$\det(\mathbf{A}) = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11}a_{22} - a_{12}a_{21}$$

Determinant

$$L = \begin{bmatrix} \ell_{1,1} & & & & 0 \\ \ell_{2,1} & \ell_{2,2} & & & \\ \ell_{3,1} & \ell_{3,2} & \ddots & & \\ \vdots & \vdots & \ddots & \ddots & \\ \ell_{n,1} & \ell_{n,2} & \dots & \ell_{n,n-1} & \ell_{n,n} \end{bmatrix}$$

$$U = \begin{bmatrix} u_{1,1} & u_{1,2} & u_{1,3} & \dots & u_{1,n} \\ & u_{2,2} & u_{2,3} & \dots & u_{2,n} \\ & & \ddots & \ddots & \vdots \\ & & & \ddots & u_{n-1,n} \\ 0 & & & & u_{n,n} \end{bmatrix}$$


Bir \mathbf{T} matrisinde, $i > j$ (ya da $i < j$) değerleri için eğer $T_{ij} = 0$ ise matrisin determinanı

$$\det(\mathbf{T}) = \prod_{i=1}^n T_{ii}$$

şeklinde hesaplanır.




Determinant; **uzunluk**, alan, hacim,







Determinant; uzunluk, **alan**, hacim,




Determinant; uzunluk, **alan**, hacim,




Determinant; uzunluk, **alan**, hacim,



Determinant; uzunluk, **alan**, hacim,




Determinant; uzunluk, **alan**, hacim,



$$\mathbf{A} = [b, g]$$

$$\begin{vmatrix} b & 0 \\ 0 & g \end{vmatrix} = bg - 0 = bg.$$



Doğrusal bağımlı **b** ve **g** sütun vektörleri için hem alan hem determinant 0 olur




$$\mathbf{A} = \begin{bmatrix} b & a \\ d & c \end{bmatrix}$$

$$\begin{aligned} \det(\mathbf{A}) &= ((a+b) \times (c+d)) - ((a+b) \times c + b \times (c+d)) \\ &= ac + ad + bc + bd - ac - bc - bc - bd \\ &= -(bc - ad) \end{aligned}$$

Determinant; uzunluk, **alan**, hacim,



Determinant; uzunluk, alan, **hacim**,



$$A = [r, b, g]$$

$$r = \begin{bmatrix} 2 \\ 0 \\ -8 \end{bmatrix}, \quad g = \begin{bmatrix} 6 \\ 1 \\ 0 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 4 \\ -1 \end{bmatrix}$$

$$A = [r, g, b] = \begin{bmatrix} 2 & 6 & 1 \\ 0 & 1 & 4 \\ -8 & 0 & -1 \end{bmatrix}$$

$$V = |\det(A)| = 186$$




Determinant


$$\begin{bmatrix} \alpha_1 & & \\ & \ddots & \\ & & \alpha_i & \\ & & & \ddots \\ & & & & \alpha_n \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_i \\ \vdots \\ x_n \end{bmatrix} = x_1 \begin{bmatrix} \alpha_1 \\ \vdots \\ \vdots \\ \vdots \\ \vdots \end{bmatrix} + \cdots + x_i \begin{bmatrix} \vdots \\ \vdots \\ \alpha_i \\ \vdots \\ \vdots \end{bmatrix} + \cdots + x_n \begin{bmatrix} \vdots \\ \vdots \\ \vdots \\ \vdots \\ \alpha_n \end{bmatrix}$$

Köşegensel
matrisler


A




B



C



D







Determinant

Kayma
matrisleri

$$\begin{bmatrix} \alpha_1 & \dots & \beta \\ & \ddots & \vdots \\ & & \alpha_i \\ & & & \ddots \\ & & & & \alpha_n \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_i \\ \vdots \\ x_n \end{bmatrix} = x_1 \begin{bmatrix} \alpha_1 \\ \vdots \\ \vdots \\ \vdots \\ \vdots \end{bmatrix} + \dots + x_i \begin{bmatrix} \beta \\ \vdots \\ \alpha_i \\ \vdots \\ \vdots \end{bmatrix} + \dots + x_n \begin{bmatrix} \vdots \\ \vdots \\ \vdots \\ \vdots \\ \alpha_n \end{bmatrix}$$







Determinant

Ortogonal matris, sütun vektörleri birim vektörler ve birbirlerine dik olan kare matrislerdir. İki vektör birbirine dik ise iç çarpımları 0'dır.

Ortogonal
matrisler



Ortogonal olmayan vektörler



Ortogonal olan vektörler

$$A^T A = \begin{bmatrix} \frac{\mathbf{a}_1^T}{\|\mathbf{a}_1\|} \\ \frac{\mathbf{a}_2^T}{\|\mathbf{a}_2\|} \\ \vdots \\ \frac{\mathbf{a}_n^T}{\|\mathbf{a}_n\|} \end{bmatrix} \begin{bmatrix} \mathbf{a}_1 & \mathbf{a}_2 & \dots & \mathbf{a}_n \end{bmatrix} = \begin{bmatrix} 1 & & & \\ & 1 & & \\ & & \ddots & \\ & & & 1 \end{bmatrix} = I_n$$



Determinant

- Ortogonal matrislerin sağladığı dönüşüm vektörler arasındaki açıyı korur
- Ortogonal matrislerin sağladığı dönüşüm vektörlerin uzunluklarını korur
- Ortogonal matrislerin determinantları 1 ya da -1'dir


$$\begin{aligned} A\mathbf{v}_i \cdot A\mathbf{v}_j &= (A\mathbf{v}_i)^\top (A\mathbf{v}_j) \\ &= \mathbf{v}_i^\top A^\top A \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{v}_j \\ &= \mathbf{v}_i \cdot \mathbf{v}_j \end{aligned}$$

$$\begin{aligned} \|A\mathbf{v}\|_2^2 &= A\mathbf{v} \cdot A\mathbf{v} \\ &= (A\mathbf{v})^\top (A\mathbf{v}) \\ &= \mathbf{v}^\top A^\top A \mathbf{v} \\ &= \mathbf{v}^\top \mathbf{v} \\ &= \mathbf{v} \cdot \mathbf{v} \\ &= \|\mathbf{v}\|_2^2 \end{aligned}$$

$$\begin{aligned} 1 &= \det(I_n) = \det(A^\top A) : \\ &= \det(A^\top) \det(A) = (\det(A))^2 \end{aligned}$$



Determinant




Teorem: Bir $\mathbf{A} \in \mathbb{R}^{n \times n}$ matrisimiz olsun. Bütün $j = 1, \dots, n$ değerleri için:

- 1) j sütunundan yapılan **Laplace açılımı** ile

$$\det(\mathbf{A}) = \sum_{k=1}^n (-1)^{k+j} a_{kj} \det(\mathbf{A}_{k,j})$$

- 2) j satırından yapılan Laplace açılımı ile

$$\det(\mathbf{A}) = \sum_{k=1}^n (-1)^{k+j} a_{jk} \det(\mathbf{A}_{j,k})$$



Burada $\mathbf{A}_{k,j} \in \mathbb{R}^{(n-1) \times (n-1)}$ satır k ve sütun j 'yi silerek elde edilen alt-matrisi ifade eder.

Determinant

Örnek:

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 3 & 1 & 2 \\ 0 & 0 & 1 \end{bmatrix} \text{ matrisi için}$$

ilk satır üzerinden yapılan Laplace açılımı ile

$$\begin{vmatrix} 1 & 2 & 3 \\ 3 & 1 & 2 \\ 0 & 0 & 1 \end{vmatrix} = (-1)^{1+1} \cdot 1 \begin{vmatrix} 1 & 2 \\ 0 & 1 \end{vmatrix} \\ + (-1)^{1+2} \cdot 2 \begin{vmatrix} 3 & 2 \\ 0 & 1 \end{vmatrix} + (-1)^{1+3} \cdot 3 \begin{vmatrix} 3 & 1 \\ 0 & 0 \end{vmatrix}$$

$$\det(\mathbf{A}) = 1(1 - 0) - 2(3 - 0) + 3(0 - 0) = -5$$

Ya da $\det(\mathbf{A}) = 1 \cdot 1 \cdot 1 + 3 \cdot 0 \cdot 3 + 0 \cdot 2 \cdot 2 - 0 \cdot 1 \cdot 3 - 1 \cdot 0 \cdot 2 - 3 \cdot 2 \cdot 1 = 1 - 6 = -5$



Determinant

- Matrisin iki satırı ya da iki sütunu yer değiştirirse determinant -1 ile çarpılır.
- Matrisin bir satırı (sütunu) başka bir satıra (sütuna) eklenirse determinant değişmez.
- Bir \mathbf{A} matrisinin tersi varsa $\det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}$

$$\det(\lambda \mathbf{A}) = \lambda^n \det(\mathbf{A})$$

$$\det(\mathbf{AB}) = \det(\mathbf{A})\det(\mathbf{B})$$

$$\det(\mathbf{A}) = \det(\mathbf{A}^\top)$$

- $\mathbf{A} \in \mathbb{R}^{n \times n}$ kare matrisinin determinantı ancak ve ancak mertebesi n ise 0'dan farklıdır.



İz (Trace)

Bir $\mathbf{A} \in \mathbb{R}^{n \times n}$ matrisinin **izi**, köşegenindeki değerlerin toplamına eşittir:

$$\text{tr}(\mathbf{A}) := \sum_{i=1}^n a_{ii}$$

İz'in şu özellikleri vardır

- $\text{tr}(\mathbf{A} + \mathbf{B}) = \text{tr}(\mathbf{A}) + \text{tr}(\mathbf{B})$ $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$
- $\text{tr}(\alpha \mathbf{A}) = \alpha \text{tr}(\mathbf{A})$, $\alpha \in \mathbb{R}$ $\mathbf{A} \in \mathbb{R}^{n \times n}$
- $\text{tr}(\mathbf{I}_n) = n$
- $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$ $\mathbf{A} \in \mathbb{R}^{n \times k}$, $\mathbf{B} \in \mathbb{R}^{k \times n}$



İz

İz fonksiyonu dögüsel permütasyonlar altında değışmezdir

$$\text{tr}(\mathbf{AKL}) = \text{tr}(\mathbf{KLA})$$

$$\mathbf{A} \in \mathbb{R}^{a \times k}, \mathbf{K} \in \mathbb{R}^{k \times l}, \mathbf{L} \in \mathbb{R}^{l \times a}$$

$$\text{tr}(\mathbf{xy}^\top) = \text{tr}(\mathbf{y}^\top \mathbf{x}) = \mathbf{y}^\top \mathbf{x} \in \mathbb{R}$$

$$\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$$

Bir \mathbf{V} vektör uzayı ve $\Phi : \mathbf{V} \rightarrow \mathbf{V}$ eşlemesi için dönüşüm matrisi \mathbf{A} olsun. Farklı bir baz kullanıldığında ise dönüşüm matrisi $\mathbf{B} = \mathbf{S}^{-1}\mathbf{A}\mathbf{S}$ olsun.

$$\text{tr}(\mathbf{B}) = \text{tr}(\mathbf{S}^{-1}\mathbf{A}\mathbf{S}) = \text{tr}(\mathbf{A}\mathbf{S}\mathbf{S}^{-1}) = \text{tr}(\mathbf{A})$$

olur. Doğrusal dönüşümlerin matrisleri baz ile değışse de dönüşümün izi farklı baz kullanıldığında değışmez.



Karakteristik Polinom

Bir $\lambda \in \mathbb{R}$ ve bir kare matris $\mathbf{A} \in \mathbb{R}^{n \times n}$ için **karakteristik polinom**

$$\begin{aligned} p_{\mathbf{A}}(\lambda) &:= \det(\mathbf{A} - \lambda \mathbf{I}) \\ &= c_0 + c_1 \lambda + c_2 \lambda^2 + \cdots + c_{n-1} \lambda^{n-1} + (-1)^n \lambda^n \end{aligned}$$

$c_0, \dots, c_{n-1} \in \mathbb{R}$ şeklinde gösterilir. Burada şu eşitlikler önemlidir.

$$\begin{aligned} c_0 &= \det(\mathbf{A}), \\ c_{n-1} &= (-1)^{n-1} \text{tr}(\mathbf{A}) \end{aligned}$$

Özdeğer (eigenvalue) ve özvektör (eigenvector)

$A \in \mathbb{R}^{n \times n}$ kare bir matris olsun:

$$Ax = \lambda x$$

eşitliğini sağlayan $\lambda \in \mathbb{R}$ değerine A matrisinin bir **özdeğeri**, buna eşlenik $x \in \mathbb{R}^n \setminus \{0\}$ vektörüne de A matrisinin bir **özvektörü** denir. Aşağıdaki ifadeler eşdeğerdir:

- $\lambda \in \mathbb{R}$ değeri $A \in \mathbb{R}^{n \times n}$ matrisinin bir özdeğerdir.
- $(A - \lambda I_n)x = 0$ ifadesinin 0 'dan farklı bir $x \neq 0$ çözümü vardır.
- $\text{rk}(A - \lambda I_n) < n$
- $\det(A - \lambda I_n) = 0$



Özdeğerler ve özvektörler

İki vektör aynı yönü gösteriyorsa bu vektörler **yöndeştir**. Eğer vektörler aynı ya da zıt yönleri gösteriyorlarsa bu vektörler **doğrusaldır**.

Eğer \mathbf{x} vektörü \mathbf{A} matrisinin λ özdeğerine tekabül eden bir özvektörü ise, bir $c \in \mathbb{R} \setminus \{0\}$ pozitif reel sayısı için $c\mathbf{x}$ vektörü de \mathbf{A} matrisinin bir özvektörüdür.

$$\mathbf{A}(c\mathbf{x}) = c\mathbf{A}\mathbf{x} = c\lambda\mathbf{x} = \lambda(c\mathbf{x})$$

Dolayısıyla, \mathbf{x} ile doğrusal bütün vektörler \mathbf{A} matrisinin bir özvektörüdür.



Özdeğerler ve özvektörler

Teorem: Bir $\lambda \in \mathbb{R}$ reel sayısı ancak ve ancak $p_A(\lambda)$ karakteristik polinomunun bir kökü ise A matrisinin bir özdeğeridir.

λ değerinin $p_A(\lambda)$ polinomunun kökleri arasında görülme sayısına λ özdeğerinin **(cebirsal) katlılığı** denir.

Bir $A \in \mathbb{R}^{n \times n}$ matrisi için λ özdeğerine tekabül eden bütün özvektörlerin oluşturduğu uzay \mathbb{R}^n uzayının bir alt uzayıdır. Bu alt uzaya A matrisinin λ özdeğerine göre **özuzayı** denir ve E_λ ile gösterilir.


A matrisinin bütün özdeğerlerinin oluşturduğu kümeye, matrisin **özspektrumu** denir.

Eğer A birim matris ise tek özdeğeri (tekrar sayısı n olan) 1'dir. Bütün $x \in \mathbb{R}^n \setminus \{0\}$ vektörleri bir özvektördür. Dolayısıyla E_1 uzayı, \mathbb{R}^n uzayının standart baz vektörlerinin kapsadığı alt uzayıdır.

Özdeğerler ve özvektörler

Tanım: $A, \tilde{A} \in \mathbb{R}^{m \times n}$ matrisleri $\tilde{A} = T^{-1}AS$ eşitliğini sağlayan düzenli (tersi alınabilen) $S \in \mathbb{R}^{n \times n}$ ve $T \in \mathbb{R}^{m \times m}$ matrisleri bulunabiliyorsa birbirine **denktir**.

Tanım: $A, \tilde{A} \in \mathbb{R}^{n \times n}$ matrisleri $\tilde{A} = S^{-1}AS$ eşitliğini sağlayan düzenli (tersi alınabilen) bir $S \in \mathbb{R}^{n \times n}$ matrisi bulunabiliyorsa birbirine **benzerdir**.





Özdeğerler ve özvektörler

- Bir matrisin kendisi ve devriği aynı özdeğerlere sahiptir.
 - Fakat özvektörleri farklı olabilir.
- Bir E_λ alt uzayı $A - \lambda I$ 'in sıfır uzayına eşittir.

$$\begin{aligned} Ax = \lambda x &\iff Ax - \lambda x = 0 \\ &\iff (A - \lambda I)x = 0 \iff x \in \ker(A - \lambda I) \end{aligned}$$

- Benzer matrislerin **özspektrumu** aynıdır. Bu da doğrusal bir eşleme Φ 'nin özdeğerlerinin dönüşüm matrisi için kullanılan baz vektörlerinden bağımsız olduğunu gösterir. Dolayısıyla özdeğerler, determinant ve iz bir eşleme için baz değişikliği durumlarında değişmez
- Simetrik ve **pozitif kesin** (kesin artı) matrisler her zaman pozitif ve reel özdeğerlere sahiptir.

$$\mathbf{x}^T \mathbf{A} \mathbf{x} > 0 \text{ for } \mathbf{x} \neq \mathbf{0}$$



Özdeğerler ve özvektörler

Örnek: $\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 1 & 3 \end{bmatrix}$ matrisinin özdeğerleri şu şekilde bulunur.

$$\begin{aligned} p_{\mathbf{A}}(\lambda) &= \det(\mathbf{A} - \lambda \mathbf{I}) \\ &= \det \left(\begin{bmatrix} 4 & 2 \\ 1 & 3 \end{bmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} \right) = \begin{vmatrix} 4 - \lambda & 2 \\ 1 & 3 - \lambda \end{vmatrix} \\ &= (4 - \lambda)(3 - \lambda) - 2 \cdot 1. \end{aligned}$$

$$p(\lambda) = (4 - \lambda)(3 - \lambda) - 2 \cdot 1 = 10 - 7\lambda + \lambda^2 = (2 - \lambda)(5 - \lambda)$$

$$\lambda_1 = 2 \quad \lambda_2 = 5$$



Özdeğerler ve özvektörler

Özvektörler ve özuzay hesabı şu şekilde yapılabilir

$$\begin{bmatrix} 4 - \lambda & 2 \\ 1 & 3 - \lambda \end{bmatrix} \mathbf{x} = \mathbf{0}$$

$$\begin{aligned} \mathbf{Ax} &= \lambda \mathbf{x} \\ \mathbf{Ax} &= \mathbf{I}\lambda \mathbf{x} \\ (\mathbf{A} - \mathbf{I}\lambda) \mathbf{x} &= \mathbf{0} \end{aligned}$$

$$(\lambda = 5)$$

$$\begin{bmatrix} 4 - 5 & 2 \\ 1 & 3 - 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} -1 & 2 \\ 1 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \mathbf{0}$$

$$E_5 = \text{span} \left[\begin{bmatrix} 2 \\ 1 \end{bmatrix} \right]$$



Özdeğerler ve özvektörler

Özvektörler ve özuzay hesabı şu şekilde yapılabilir

$$\begin{bmatrix} 4 - \lambda & 2 \\ 1 & 3 - \lambda \end{bmatrix} \mathbf{x} = \mathbf{0}$$

$$\begin{aligned} \mathbf{Ax} &= \lambda \mathbf{x} \\ \mathbf{Ax} &= \mathbf{I}\lambda \mathbf{x} \\ (\mathbf{A} - \mathbf{I}\lambda) \mathbf{x} &= \mathbf{0} \end{aligned}$$

$$(\lambda = 2) \quad \begin{bmatrix} 4 - 2 & 2 \\ 1 & 3 - 2 \end{bmatrix} \mathbf{x} = \begin{bmatrix} 2 & 2 \\ 1 & 1 \end{bmatrix} \mathbf{x} = \mathbf{0}$$

$$E_2 = \text{span}\left[\begin{bmatrix} 1 \\ -1 \end{bmatrix}\right]$$

Özdeğerler ve özvektörler

Örnek: $A = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 4 \\ 0 & 4 & 9 \end{bmatrix}$

$$\begin{aligned} |A - \lambda I| &= \left| \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 4 \\ 0 & 4 & 9 \end{bmatrix} - \lambda \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \right| = \begin{vmatrix} 2-\lambda & 0 & 0 \\ 0 & 3-\lambda & 4 \\ 0 & 4 & 9-\lambda \end{vmatrix} \\ &= (2-\lambda)[(3-\lambda)(9-\lambda) - 16] = -\lambda^3 + 14\lambda^2 - 35\lambda + 22 \end{aligned}$$

Özdeğerler

2

1

11

$$[1 \ 0 \ 0]^T$$

$$[0 \ -2 \ 1]^T$$

$$[0 \ 1 \ 2]^T$$

Özdeğerler ve özvektörler

Örnek: $A = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 4 \\ 0 & 4 & 9 \end{bmatrix}$

$$\begin{bmatrix} 2 - \lambda & 0 & 0 \\ 0 & 3 - \lambda & 4 \\ 0 & 4 & 9 - \lambda \end{bmatrix} \mathbf{x} = \mathbf{0}$$

Özdeğerler:

2

$$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 4 \\ 0 & 4 & 7 \end{bmatrix} \mathbf{x} = \mathbf{0}$$

1

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 4 \\ 0 & 4 & 8 \end{bmatrix} \mathbf{x} = \mathbf{0}$$

11

$$\begin{bmatrix} -9 & 0 & 0 \\ 0 & -8 & 4 \\ 0 & 4 & -2 \end{bmatrix} \mathbf{x} = \mathbf{0}$$

Özvektörler:

$$[1 \ 0 \ 0]^T$$

$$[0 \ -2 \ 1]^T$$

$$[0 \ 1 \ 2]^T$$

Özdeğerler ve özvektörler

λ_i değeri kare A matrisinin bir özdeğeri olsun. λ_i 'nin **geometrik katlılığı**, ona karşılık gelen, doğrusal bağımsız özvektörlerin sayısına eşittir.

Bir özdeğerin geometrik katlılığı onun aritmetik katlılığından küçük eşittir.

Örnek:

$$A = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}$$


$$\lambda_1 = \lambda_2 = 2$$

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$


$$\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \mathbf{x} = \mathbf{0}$$

Özdeğerler ve özvektörler


$$\mathbf{A}_1 = \begin{bmatrix} \frac{1}{2} & 0 \\ 0 & 2 \end{bmatrix}$$




$\lambda_1 = 2.0$
 $\lambda_2 = 0.5$
 $\det(\mathbf{A}) = 1.0$



$$\mathbf{A}_2 = \begin{bmatrix} 1 & \frac{1}{2} \\ 0 & 1 \end{bmatrix}$$




$\lambda_1 = 1.0$
 $\lambda_2 = 1.0$
 $\det(\mathbf{A}) = 1.0$




Özdeğerler ve özvektörler

$$\mathbf{A}_3 = \begin{bmatrix} \cos(\frac{\pi}{6}) & -\sin(\frac{\pi}{6}) \\ \sin(\frac{\pi}{6}) & \cos(\frac{\pi}{6}) \end{bmatrix} = \frac{1}{2} \begin{bmatrix} \sqrt{3} & -1 \\ 1 & \sqrt{3} \end{bmatrix}$$




$$\begin{aligned}\lambda_1 &= (0.87-0.5j) \\ \lambda_2 &= (0.87+0.5j) \\ \det(\mathbf{A}) &= 1.0\end{aligned}$$




Özdeğerler ve özvektörler


$$\mathbf{A}_4 = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}$$




$$\begin{aligned}\lambda_1 &= 0.0 \\ \lambda_2 &= 2.0 \\ \det(\mathbf{A}) &= 0.0\end{aligned}$$

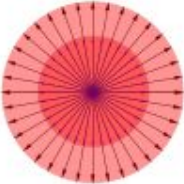
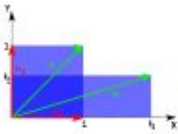
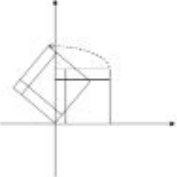
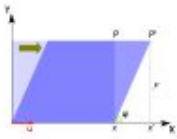
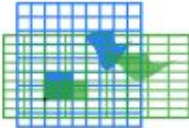


$$\mathbf{A}_5 = \begin{bmatrix} 1 & \frac{1}{2} \\ \frac{1}{2} & 1 \end{bmatrix}$$




$$\begin{aligned}\lambda_1 &= 0.5 \\ \lambda_2 &= 1.5 \\ \det(\mathbf{A}) &= 0.75\end{aligned}$$





	Scaling	Unequal scaling	Rotation	Horizontal shear	Hyperbolic rotation
Illustration					
Matrix	$\begin{bmatrix} k & 0 \\ 0 & k \end{bmatrix}$	$\begin{bmatrix} k_1 & 0 \\ 0 & k_2 \end{bmatrix}$	$\begin{bmatrix} c & -s \\ s & c \end{bmatrix}$ $c = \cos \theta$ $s = \sin \theta$	$\begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}$	$\begin{bmatrix} c & s \\ s & c \end{bmatrix}$ $c = \cosh \varphi$ $s = \sinh \varphi$
Characteristic polynomial	$(\lambda - k)^2$	$(\lambda - k_1)(\lambda - k_2)$	$\lambda^2 - 2c\lambda + 1$	$(\lambda - 1)^2$	$\lambda^2 - 2c\lambda + 1$
Eigenvalues, λ_i	$\lambda_1 = \lambda_2 = k$	$\lambda_1 = k_1$ $\lambda_2 = k_2$	$\lambda_1 = e^{i\theta} = c + s\mathbf{i}$ $\lambda_2 = e^{-i\theta} = c - s\mathbf{i}$	$\lambda_1 = \lambda_2 = 1$	$\lambda_1 = e^{\varphi}$ $\lambda_2 = e^{-\varphi}$
Algebraic mult., $\mu_i = \mu(\lambda_i)$	$\mu_1 = 2$	$\mu_1 = 1$ $\mu_2 = 1$	$\mu_1 = 1$ $\mu_2 = 1$	$\mu_1 = 2$	$\mu_1 = 1$ $\mu_2 = 1$
Geometric mult., $\gamma_i = \gamma(\lambda_i)$	$\gamma_1 = 2$	$\gamma_1 = 1$ $\gamma_2 = 1$	$\gamma_1 = 1$ $\gamma_2 = 1$	$\gamma_1 = 1$	$\gamma_1 = 1$ $\gamma_2 = 1$
Eigenvectors	All nonzero vectors	$u_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$ $u_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$	$u_1 = \begin{bmatrix} 1 \\ -\mathbf{i} \end{bmatrix}$ $u_2 = \begin{bmatrix} 1 \\ +\mathbf{i} \end{bmatrix}$	$u_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$	$u_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ $u_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$

Özdeğerler ve özvektörler



C. elegans sinir ağı

$$A \in \mathbb{R}^{277 \times 277}$$



$$A_{sym} := A + A^T$$



Özdeğerler ve özvektörler

Teorem: Bir $A \in \mathbb{R}^{n \times n}$ kare matrisinin n tane birbirinden farklı $\lambda_1, \dots, \lambda_n$ özdeğeri varsa, x_1, \dots, x_n özvektörleri birbirinden doğrusal bağımsızdır.

Bu vektörler \mathbb{R}^n için bir baz oluşturur.

Kare bir $A \in \mathbb{R}^{n \times n}$ matrisinin n doğrusal bağımsız özvektörü yoksa, matris **arızalı** olarak tanımlanır. *Arızalı olmayan matrislerin* n farklı özdeğere ihtiyacı yoktur ama özvektörlerin \mathbb{R}^n için bir baz oluşturması gereklidir.

$$J = \begin{bmatrix} \lambda & 1 & & \\ & \lambda & \ddots & \\ & & \ddots & 1 \\ & & & \lambda \end{bmatrix} \quad v = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$



Özdeğerler ve özvektörler

Teorem: Bir $A \in \mathbb{R}^{n \times n}$ kare matrisinin n tane birbirinden farklı $\lambda_1, \dots, \lambda_n$ özdeğerleri varsa, x_1, \dots, x_n özvektörleri birbirinden doğrusal bağımsızdır.

Bu vektörler \mathbb{R}^n için bir baz oluşturur.

Kare bir $A \in \mathbb{R}^{n \times n}$ matrisinin n doğrusal bağımsız özvektörü yoksa, matris **arızalı** olarak tanımlanır. *Arızalı olmayan matrislerin* n farklı özdeğere ihtiyacı yoktur ama özvektörlerin \mathbb{R}^n için bir baz oluşturması gereklidir.

Dolayısıyla arızalı matrislerin özuzaylarının boyut toplamı n 'den küçüktür. Özetle, arızalı bir matrisin aritmetik katlılığı $m > 1$ olan ama geometrik katlılığı m 'den küçük bir λ_i (arızalı) özdeğeri vardır.



Özdeğerler ve özvektörler

Teorem: Bir $\mathbf{A} \in \mathbb{R}^{m \times n}$ matrisi için $\mathbf{S} := \mathbf{A}^\top \mathbf{A}$ simetrik ve yarı pozitif tanımlı bir matristir. Matrisin mertebesi $\text{rk}(\mathbf{A}) = n$ ise $\mathbf{S} \in \mathbb{R}^{n \times n}$ pozitif tanımlı bir matristir.

Simetri: $\mathbf{S} = \mathbf{A}^\top \mathbf{A} = \mathbf{A}^\top (\mathbf{A}^\top)^\top = (\mathbf{A}^\top \mathbf{A})^\top = \mathbf{S}^\top$

Yarı pozitif tanımlılık: $\mathbf{x}^\top \mathbf{S} \mathbf{x} = \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} = (\mathbf{x}^\top \mathbf{A}^\top)(\mathbf{A} \mathbf{x}) = (\mathbf{A} \mathbf{x})^\top (\mathbf{A} \mathbf{x}) \geq 0$



Özdeğerler ve özvektörler

Teorem: Eğer $\mathbf{A} \in \mathbb{R}^{n \times n}$ simetrik bir matris ise

- matrisin özdeğerleri birbirinden farklı ve reeldir.
- farklı özdeğerlere tekabül eden özvektörler birbirine ortogonaldır.
- \mathbf{P} ortogonal bir matris, \mathbf{D} ise köşegensel bir matris olmak üzere

$$\mathbf{A} = \mathbf{P}\mathbf{D}\mathbf{P}^T$$

eşitliğini sağlayacak \mathbf{P} ve \mathbf{D} matrisleri bulunabilir.

Burada \mathbf{D} 'nin köşegenindeki değerler \mathbf{A} matrisinin özdeğerleri, \mathbf{P} matrisinin sütunları ise \mathbf{A} 'nın özvektörleridir.

Özdeğerler ve özvektörler

Örnek:

$$A = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & 2 \\ 2 & 2 & 3 \end{bmatrix}$$

$$p_A(\lambda) = -(\lambda - 1)^2(\lambda - 7)$$

$$E_1 = \text{span}\left[\underbrace{\begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}}_{=: \mathfrak{x}_1}, \underbrace{\begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}}_{=: \mathfrak{x}_2}\right], \quad E_7 = \text{span}\left[\underbrace{\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}}_{=: \mathfrak{x}_3}\right]$$

$$\begin{bmatrix} 2 & 2 & 2 \\ 2 & 2 & 2 \\ 2 & 2 & 2 \end{bmatrix} \mathbf{x} = \mathbf{0}$$

$$\begin{bmatrix} -4 & 2 & 2 \\ 2 & -4 & 2 \\ 2 & 2 & -4 \end{bmatrix} \mathbf{x} = \mathbf{0}$$

$$\begin{aligned} & ((3 - \lambda)^3 + 16) - (12 + (3 - \lambda)) \\ & -\lambda^3 + 9\lambda^2 - 27\lambda + 27 + 16 - 36 + 12\lambda \\ & -\lambda^3 + 9\lambda^2 - 15\lambda + 7 \end{aligned}$$

$$\begin{aligned} \mathbf{x} &= [x_1 \quad x_2 \quad x_3]^T \\ x_1 + x_2 + x_3 &= 0 \\ x_1 &= -\alpha - \beta, x_2 = \alpha, x_3 = \beta, \end{aligned}$$

$$\begin{aligned} \mathbf{x} &= [x_1 \quad x_2 \quad x_3]^T \\ \rightarrow \begin{bmatrix} -4 & 2 & 2 \\ 0 & -3 & 3 \\ 0 & 3 & -3 \end{bmatrix} &\rightarrow \begin{bmatrix} -4 & 2 & 2 \\ 0 & -3 & 3 \\ 0 & 0 & 0 \end{bmatrix} \\ x_1 &= x_2 = x_3 = \alpha \end{aligned}$$

Özdeğerler ve özvektörler

Örnek:

$$A = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & 2 \\ 2 & 2 & 3 \end{bmatrix}$$

$$p_A(\lambda) = -(\lambda - 1)^2(\lambda - 7)$$

$$E_1 = \text{span}\left[\underbrace{\begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}}_{=:x_1}, \underbrace{\begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}}_{=:x_2}\right], \quad E_7 = \text{span}\left[\underbrace{\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}}_{=:x_3}\right]$$

$$A(\alpha x_1 + \beta x_2) = Ax_1\alpha + Ax_2\beta = \lambda(\alpha x_1 + \beta x_2)$$

$$x'_1 = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}, \quad x'_2 = \frac{1}{2} \begin{bmatrix} -1 \\ -1 \\ 2 \end{bmatrix}$$

Gram-Schmidt

$$v_1 = x_1,$$

$$v_2 = x_2 - \frac{\langle x_2, v_1 \rangle}{\langle v_1, v_1 \rangle} v_1,$$

$$v_3 = x_3 - \frac{\langle x_3, v_1 \rangle}{\langle v_1, v_1 \rangle} v_1 - \frac{\langle x_3, v_2 \rangle}{\langle v_2, v_2 \rangle} v_2,$$

.....

$$v_n = x_n - \frac{\langle x_n, v_1 \rangle}{\langle v_1, v_1 \rangle} v_1 - \dots - \frac{\langle x_n, v_{n-1} \rangle}{\langle v_{n-1}, v_{n-1} \rangle} v_{n-1}.$$

$$x'_2 = x_2 - \frac{\langle x_1, x_2 \rangle}{\langle x_1, x_1 \rangle} x_1$$

$$\begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix} - \frac{1}{2} \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}$$



Özdeğerler ve özvektörler

$$\begin{aligned} p_A(\lambda) &:= \det(\mathbf{A} - \lambda \mathbf{I}) \\ &= c_0 + c_1 \lambda + c_2 \lambda^2 + \cdots + c_{n-1} \lambda^{n-1} + (-1)^n \lambda^n \end{aligned}$$

Teorem: $\mathbf{A} \in \mathbb{R}^{n \times n}$ matrisinin determinanı (tekrarlanabilen) özdeğerlerin çarpımına eşittir. Matrisin özdeğerleri $\lambda_i \in \mathbb{C}$ ise, determinant

$$\det(\mathbf{A}) = \prod_{i=1}^n \lambda_i$$


olarak hesaplanır.

Teorem: $\mathbf{A} \in \mathbb{R}^{n \times n}$ matrisinin izi (tekrarlanabilen) özdeğerlerin toplamına eşittir. Matrisin özdeğerleri $\lambda_i \in \mathbb{C}$ ise, iz

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n \lambda_i$$

olarak hesaplanır.

Özdeğerler ve özvektörler





Cholesky ayrıştırması

Teorem: Simetrik ve pozitif kesin bir \mathbf{A} matrisi, \mathbf{L} köşegen değerleri pozitif olan alt üçgensel bir matris olmak üzere $\mathbf{A} = \mathbf{L}\mathbf{L}^\top$ şeklinde çarpanlarına ayrılabilir.

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} = \begin{bmatrix} l_{11} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ l_{n1} & \cdots & l_{nn} \end{bmatrix} \begin{bmatrix} l_{11} & \cdots & l_{n1} \\ \vdots & \ddots & \vdots \\ 0 & \cdots & l_{nn} \end{bmatrix}$$

Bu ayrışmayı sağlayan sadece tek bir \mathbf{L} matrisi vardır ve \mathbf{A} matrisinin **Cholesky çarpanı** olarak tanımlanır.



Cholesky ayrıştırması

Örnek: 3x3 bir simetrik, pozitif kesin matris aşağıdaki şekilde Cholesky çarpanlarına ayrılır:

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{21} & a_{31} \\ a_{21} & a_{22} & a_{32} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \mathbf{L}\mathbf{L}^T = \begin{bmatrix} l_{11} & 0 & 0 \\ l_{21} & l_{22} & 0 \\ l_{31} & l_{32} & l_{33} \end{bmatrix} \begin{bmatrix} l_{11} & l_{21} & l_{31} \\ 0 & l_{22} & l_{32} \\ 0 & 0 & l_{33} \end{bmatrix}$$

$$\mathbf{A} = \begin{bmatrix} l_{11}^2 & l_{21}l_{11} & l_{31}l_{11} \\ l_{21}l_{11} & l_{21}^2 + l_{22}^2 & l_{31}l_{21} + l_{32}l_{22} \\ l_{31}l_{11} & l_{31}l_{21} + l_{32}l_{22} & l_{31}^2 + l_{32}^2 + l_{33}^2 \end{bmatrix}$$

$$l_{11} = \sqrt{a_{11}}, \quad l_{22} = \sqrt{a_{22} - l_{21}^2}, \quad l_{33} = \sqrt{a_{33} - (l_{31}^2 + l_{32}^2)}$$

$$l_{21} = \frac{1}{l_{11}}a_{21}, \quad l_{31} = \frac{1}{l_{11}}a_{31}, \quad l_{32} = \frac{1}{l_{22}}(a_{32} - l_{31}l_{21})$$



Cholesky ayrıştırması

- Cholesky ayrıştırması doğrusal sistem çözümlerinde büyük kolaylık sağlar.
 - Klasik LU ayrıştırmasının yarısı kadar hafıza harcar.
 - Yine $Ax = b$ çözümü için göre yaklaşık iki kat daha hızlı sonuç verir.
- Monte Carlo algoritmalarında belli bir korelasyona sahip rassal değerlerin oluşturulması esnasında kovaryans matrisinin çarpanlarına ayrılması için kullanılır.
- Daha fazla uygulama için Wikipedia'ya bakabilirsiniz.



Özayırıştırma ve köşegenleştirme

Koşegen (diyagonal) matrislerin determinant, üs alma, tersini bulma gibi hesaplamaları diğer matrislere göre oldukça kolaydır.

$$D = \begin{bmatrix} c_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & c_n \end{bmatrix}$$

- Determinant, köşegendeki değerlerin çarpımına eşittir.
- Matrisin k 'ninci kuvveti, elemanların k 'ninci kuvvetini alarak elde edilir.
- Matrisin tersi her elemanın çarpmaya göre tersi alınarak elde edilir.



Özayırıştırma ve köşegenleştirme

Tanım: $A, \tilde{A} \in \mathbb{R}^{n \times n}$ matrisleri $\tilde{A} = S^{-1}AS$ eşitliğini sağlayan düzenli (tersi alınabilen) bir $S \in \mathbb{R}^{n \times n}$ matrisi bulunabiliyorsa birbirine **benzerdir**.

Özayırıştırma için üzerinde duracağımız matrisler, köşegen matrislere benzer matrislerdir.

Özetle ilgilendiğimiz ayrıştırma

$$A = PDP^{-1}$$

şeklindeki ayrıştırmalardır.



Özayırıştırma ve köşegenleştirme

Tanım: Bir $\mathbf{A} \in \mathbb{R}^{n \times n}$ matrisi için $\mathbf{D} = \mathbf{P}^{-1}\mathbf{A}\mathbf{P}$ köşegen matrisi olacak şekilde bir $\mathbf{P} \in \mathbb{R}^{n \times n}$ matrisi bulunabiliyorsa, \mathbf{A} matrisi köşegen \mathbf{D} matrisi ile benzerdir veya **köşegenleştirilebilir** bir matristir.

$$\mathbf{D} = \begin{bmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{bmatrix} \quad \mathbf{P} := [\mathbf{p}_1, \dots, \mathbf{p}_n]$$

olsun.

$$\mathbf{A}\mathbf{P} = \mathbf{P}\mathbf{D}$$

eşitliğinin ancak ve ancak $\lambda_1, \dots, \lambda_n$ değerleri \mathbf{A} 'nın özdeğerleri, $\mathbf{p}_1, \dots, \mathbf{p}_n$ de \mathbf{A} 'nın özvektörleri ise sağlanacağını şu şekilde gösterebiliriz.



Özayırıştırma ve köşegenleştirme

$$AP = A[p_1, \dots, p_n] = [Ap_1, \dots, Ap_n],$$

$$PD = [p_1, \dots, p_n] \begin{bmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{bmatrix} = [\lambda_1 p_1, \dots, \lambda_n p_n]$$

Burada $P \in \mathbb{R}^{n \times n}$ matrisi tersi alınabilir bir matris olduğundan, mertebesi n olmalıdır. Bu da p_1, \dots, p_n vektörlerinin birbirinden doğrusal bağımsız ve \mathbb{R}^n için bir baz olmasını gerektirir.



Özayırıştırma ve köşegenleştirme

Teorem: Bir $A \in \mathbb{R}^{n \times n}$ matrisi $P \in \mathbb{R}^{n \times n}$ ve D matrisi A 'nın özdeğerlerini içeren köşegen bir matris olmak üzere


$$A = PDP^{-1}$$

şeklinde çarpanlarına ancak ve ancak özvektörleri \mathbb{R}^n için bir baz oluşturuyorsa ayrılabilir.

Dolayısıyla sadece arızalı olmayan matrislerin özayırıştırılması mümkündür ve $P \in \mathbb{R}^{n \times n}$ matrisinin sütunları A 'nın özvektörleridir.

Teorem: Bir simetrik matris her zaman köşegenleştirilebilir. Burada $P \in \mathbb{R}^{n \times n}$ ortogonal bir matristir (spektral teorem).

Özayrıştırma ve köşegenleştirme



Özayrıştırma ve köşegenleştirme

Örnek: $\mathbf{A} = \frac{1}{2} \begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix}$ matrisinin özayrıştırmasını bulunuz.

$$\begin{aligned} \det(\mathbf{A} - \lambda \mathbf{I}) &= \det \left(\begin{bmatrix} \frac{5}{2} - \lambda & -1 \\ -1 & \frac{5}{2} - \lambda \end{bmatrix} \right) & \lambda_1 &= \frac{7}{2} \\ &= \left(\frac{5}{2} - \lambda \right)^2 - 1 = \lambda^2 - 5\lambda + \frac{21}{4} = \left(\lambda - \frac{7}{2} \right) \left(\lambda - \frac{3}{2} \right) & \lambda_2 &= \frac{3}{2} \end{aligned}$$

$$\frac{1}{2} \begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix} \mathbf{p}_1 = \frac{7}{2} \mathbf{p}_1 \quad \begin{aligned} 5\alpha - 2\beta &= 7\alpha \\ -2\alpha + 5\beta &= 7\beta \end{aligned} \quad \alpha = -\beta \quad \mathbf{p}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$\frac{1}{2} \begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix} \mathbf{p}_2 = \frac{3}{2} \mathbf{p}_2 \quad \begin{aligned} 5\alpha - 2\beta &= 3\alpha \\ -2\alpha + 5\beta &= 3\beta \end{aligned} \quad \alpha = \beta \quad \mathbf{p}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Bu vektörler \mathbb{R}^2 için bir baz oluşturduğundan matrisin özayrıştırması vardır.

Özayrıştırma ve köşegenleştirme

Örnek: $\mathbf{A} = \frac{1}{2} \begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix}$ matrisinin özayrıştırmasını bulunuz.

$$\begin{aligned} \det(\mathbf{A} - \lambda \mathbf{I}) &= \det \left(\begin{bmatrix} \frac{5}{2} - \lambda & -1 \\ -1 & \frac{5}{2} - \lambda \end{bmatrix} \right) \\ &= \left(\frac{5}{2} - \lambda \right)^2 - 1 = \lambda^2 - 5\lambda + \frac{21}{4} = \left(\lambda - \frac{7}{2} \right) \left(\lambda - \frac{3}{2} \right) \end{aligned}$$

$$\lambda_1 = \frac{7}{2}$$

$$\mathbf{p}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$\lambda_2 = \frac{3}{2}$$

$$\mathbf{p}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\mathbf{P} = [\mathbf{p}_1, \mathbf{p}_2] = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}$$

$$\underbrace{\frac{1}{2} \begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix}}_{\mathbf{A}} = \underbrace{\frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}}_{\mathbf{P}} \underbrace{\begin{bmatrix} \frac{7}{2} & 0 \\ 0 & \frac{3}{2} \end{bmatrix}}_{\mathbf{D}} \underbrace{\frac{1}{\sqrt{2}} \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}}_{\mathbf{P}^{-1}}$$



Özayırıştırma ve köşegenleştirme

Matrisin $\mathbf{A} = \mathbf{PDP}^{-1}$ şeklinde bir özayırıştırması varsa

- üs alma işlemi kolaylıkla yapılabilir

$$\mathbf{A}^k = (\mathbf{PDP}^{-1})^k = \mathbf{PD}^k\mathbf{P}^{-1}$$

- determinant hesabı kolaylıkla yapılabilir

$$\begin{aligned}\det(\mathbf{A}) &= \det(\mathbf{PDP}^{-1}) = \det(\mathbf{P}) \det(\mathbf{D}) \det(\mathbf{P}^{-1}) \\ &= \det(\mathbf{D}) = \prod_i d_{ii}\end{aligned}$$



Tekil değer ayrıştırması

Tekil değer ayrıştırması (SVD) sadece kare, simetrik ya da arızasızlara değil, bütün matrislere, her zaman uygulanabilir.

Eğer $\mathbf{A} \in \mathbb{R}^{m \times n}$ doğrusal bir eşleme $\Phi : V \rightarrow W$ ise SVD ilgili vektör uzaylarının geometrisi arasındaki değişimin değerini hesaplayabilir.



Tekil değer ayrıştırması

Teorem: $\mathbf{A} \in \mathbb{R}^{m \times n}$ mertebesi $r \in [0, \min(m, n)]$ olan dikdörtgen bir matris olsun. \mathbf{A} 'nın SVDsi

$$\begin{matrix} n \\ m \end{matrix} \mathbf{A} = \begin{matrix} m \\ m \end{matrix} \mathbf{U} \begin{matrix} m \\ n \end{matrix} \mathbf{\Sigma} \begin{matrix} n \\ n \end{matrix} \mathbf{V}^{\top}$$

şeklinde hesaplanır. Burada $\mathbf{U} \in \mathbb{R}^{m \times m}$ sütunları \mathbf{u}_i , $i = 1, \dots, m$ olan ortogonal bir matris, $\mathbf{V} \in \mathbb{R}^{n \times n}$ sütunları \mathbf{v}_j , $j = 1, \dots, n$ olan ortogonal bir matristir. $\mathbf{\Sigma}$ ise değerleri $\Sigma_{ij} = 0$, $i \neq j$ ve $\Sigma_{ii} = \sigma_i > 0$ özelliklerini sağlayan $m \times n$ boyutlarında bir matristir.

Özayırıştırma ile SVD'yi karşılaştıracak olursak

$$\mathbf{S} = \mathbf{S}^{\top} = \mathbf{P} \mathbf{D} \mathbf{P}^{\top}$$

$$\mathbf{S} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^{\top}$$

$$\mathbf{U} = \mathbf{P} = \mathbf{V}, \quad \mathbf{D} = \mathbf{\Sigma}$$



Tekil değer ayrıştırması

Σ matrisinin köşegeninde bulunan σ_i , $i = 1, \dots, r$ değerlerine \mathbf{A} matrisinin **tekil değerleri** denir. \mathbf{u}_i vektörleri matrisin **sol tekil vektörleri**, \mathbf{v}_j vektörleri ise **sağ tekil vektörleri** olarak adlandırılır.

$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r$ olarak kabul edilir.

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \sigma_n \\ 0 & \dots & 0 \\ \vdots & & \vdots \\ 0 & \dots & 0 \end{bmatrix}$$

$$m > n$$

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & 0 & 0 & \dots & 0 \\ 0 & \ddots & 0 & \vdots & & \vdots \\ 0 & 0 & \sigma_m & 0 & \dots & 0 \end{bmatrix}$$

$$m < n$$

Tekil değer ayrıştırması

Σ matrisinin köşegeninde bulunan σ_i , $i = 1, \dots, r$ değerlerine \mathbf{A} matrisinin **tekil değerleri** denir. \mathbf{u}_i vektörleri matrisin **sol tekil vektörleri**, \mathbf{v}_j vektörleri ise **sağ tekil vektörleri** olarak adlandırılır.

The diagram illustrates the SVD decomposition of matrix A (size $n \times d$) into three matrices: \hat{U} (size $n \times r$), $\hat{\Sigma}$ (size $r \times r$), and \hat{V}^T (size $r \times d$). The full matrices U (size $n \times n$), Σ (size $n \times d$), and V^T (size $d \times d$) are also shown, with the top-left $r \times r$ blocks corresponding to the $\hat{\cdot}$ matrices.

$$\begin{matrix} \boxed{\begin{matrix} A \\ n \times d \end{matrix}} & = & \boxed{\begin{matrix} \hat{U} \\ n \times r \end{matrix}} & \boxed{\begin{matrix} \hat{\Sigma} \\ r \times r \end{matrix}} & \boxed{\begin{matrix} \hat{V}^T \\ r \times d \end{matrix}} \\ & & U & \Sigma & V^T \\ & & n \times n & n \times d & d \times d \end{matrix}$$


$$\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T \rightarrow \mathbf{A}\mathbf{V} = \mathbf{U}\Sigma \rightarrow \begin{bmatrix} \mathbf{A}\mathbf{v}_1 = \sigma_1 \mathbf{u}_1 \\ \mathbf{A}\mathbf{v}_2 = \sigma_2 \mathbf{u}_2 \\ \dots \\ \mathbf{A}\mathbf{v}_r = \sigma_r \mathbf{u}_r \end{bmatrix}$$

Tekil değer ayrıştırması


$$\begin{matrix} n \\ m \end{matrix} \mathbf{A} = \begin{matrix} m \\ m \end{matrix} \mathbf{U} \begin{matrix} n \\ m \end{matrix} \mathbf{\Sigma} \begin{matrix} n \\ n \end{matrix} \mathbf{V}^T$$

SVD ayrıştırması \mathbf{A} matrisinin uyguladığı dönüşümü 3'e ayırır.

1. Önce \mathbf{V}^T ile \mathbb{R}^n uzayında gerekli baz değişikliği yapılır. Bu sayede yeni baz \mathbf{v}_j , $j = 1, \dots, n$ vektörleri olur.
2. Daha sonra $\mathbf{\Sigma}$ ile esnetme/kısaltma işlemi gerçekleşir. Burada her baz vektörü ilgili tekil değer ile çarpılır. Bunun yanında yeni boyut eklenebilir (ya da $m < n$ ise çıkarılabilir).
3. Son olarak \mathbf{U} matrisi ile geometri tekrar standart baza dönüştürülür.







Tekil değer ayrıştırması



Tekil değer ayrıştırması

Örnek:

$$\mathbf{A} = \begin{bmatrix} 1 & -0.8 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$$
$$= \begin{bmatrix} -0.79 & 0 & -0.62 \\ 0.38 & -0.78 & -0.49 \\ -0.48 & -0.62 & 0.62 \end{bmatrix} \begin{bmatrix} 1.62 & 0 \\ 0 & 1.0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} -0.78 & 0.62 \\ -0.62 & -0.78 \end{bmatrix}$$





Tekil değer ayrıştırması

SVD için \mathbf{U} ve \mathbf{V} matrislerinin bulunmasına ihtiyaç vardır. Önce \mathbf{V} matrisinden başlayalım.

$$\mathbf{A}^\top \mathbf{A} = \mathbf{P} \mathbf{D} \mathbf{P}^\top = \mathbf{P} \begin{bmatrix} \lambda_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \lambda_n \end{bmatrix} \mathbf{P}^\top$$

eşitliğinde $\mathbf{A}^\top \mathbf{A}$ simetrik olduğundan eşitliği sağlayan matrisler bulunabilir. Eğer \mathbf{A} matrisinin SVDsi var ise $\mathbf{A}^\top \mathbf{A}$ şu şekilde de yazılabilir.

$$\mathbf{A}^\top \mathbf{A} = (\mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top)^\top (\mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top) = \mathbf{V} \mathbf{\Sigma}^\top \mathbf{U}^\top \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top$$

\mathbf{U} ortonormal bir matris olduğundan $\mathbf{U}^\top \mathbf{U} = \mathbf{I}$ olur

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \mathbf{\Sigma}^\top \mathbf{\Sigma} \mathbf{V}^\top = \mathbf{V} \begin{bmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \sigma_n^2 \end{bmatrix} \mathbf{V}^\top$$

$$\begin{aligned} \mathbf{V}^\top &= \mathbf{P}^\top \\ \sigma_i^2 &= \lambda_i \end{aligned}$$



Tekil değer ayrıştırması

\mathbf{U} matrisinin hesabı benzerdir.

$$\mathbf{A}\mathbf{A}^\top = \mathbf{S}\mathbf{D}\mathbf{S}^\top$$

eşitliğinde $\mathbf{A}\mathbf{A}^\top$ simetrik bir matris olduğundan bunu sağlayan matrisler bulunabilir. Eğer \mathbf{A} matrisinin SVDsi var ise $\mathbf{A}\mathbf{A}^\top$ şu şekilde de yazılabilir.

$$\mathbf{A}\mathbf{A}^\top = (\mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top)(\mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top)^\top = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top\mathbf{V}\mathbf{\Sigma}^\top\mathbf{U}^\top$$

\mathbf{V} ortonormal bir matris olduğundan $\mathbf{V}^\top\mathbf{V} = \mathbf{I}$ olur ve

$$\mathbf{A}\mathbf{A}^\top = \mathbf{U} \begin{bmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \sigma_m^2 \end{bmatrix} \mathbf{U}^\top$$

$\mathbf{A}\mathbf{A}^\top$ ve $\mathbf{A}^\top\mathbf{A}$ 'nın özdeğerleri aynı olduğundan $\mathbf{\Sigma}$ matrisleri de aynıdır.



Tekil değer ayrıştırma

Aslında bir önceki yansıdaki, \mathbf{U} için yaptığımız işlemlere ihtiyacımız yok.

$$\begin{aligned} \mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \rightarrow \mathbf{A}\mathbf{V} = \mathbf{U}\mathbf{\Sigma} \rightarrow & \begin{aligned} \mathbf{A}\mathbf{v}_1 &= \sigma_1 \mathbf{u}_1 \\ \mathbf{A}\mathbf{v}_2 &= \sigma_2 \mathbf{u}_2 \\ \dots & \\ \mathbf{A}\mathbf{v}_r &= \sigma_r \mathbf{u}_r \end{aligned} \rightarrow \mathbf{u}_i = \frac{\mathbf{A}\mathbf{v}_i}{\sigma_i}, 1 \leq i \leq r \end{aligned}$$

Burada \mathbf{u}_i , $1 \leq i \leq r$ ortonormal bir baz oluşturuyor:

$$(\mathbf{A}\mathbf{v}_i)^\top (\mathbf{A}\mathbf{v}_j) = \mathbf{v}_i^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{v}_j = \mathbf{v}_i^\top (\lambda_j \mathbf{v}_j) = \lambda_j \mathbf{v}_i^\top \mathbf{v}_j = 0$$

$$\mathbf{u}_i^\top \mathbf{u}_i = \frac{\lambda_i \mathbf{v}_i^\top \mathbf{v}_i}{\sigma_i^2} = 1$$

Tekil değer ayrıştırması

Örnek: $\mathbf{A} = \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix}$

$$\mathbf{A}^\top \mathbf{A} = \begin{bmatrix} 1 & -2 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 5 & -2 & 1 \\ -2 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

$$\mathbf{A}^\top \mathbf{A} = \begin{bmatrix} \frac{5}{\sqrt{30}} & 0 & \frac{-1}{\sqrt{6}} \\ \frac{-2}{\sqrt{30}} & \frac{1}{\sqrt{5}} & \frac{-2}{\sqrt{6}} \\ \frac{1}{\sqrt{30}} & \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{6}} \end{bmatrix} \begin{bmatrix} 6 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{5}{\sqrt{30}} & \frac{-2}{\sqrt{30}} & \frac{1}{\sqrt{30}} \\ 0 & \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} \\ \frac{-1}{\sqrt{6}} & \frac{-2}{\sqrt{6}} & \frac{1}{\sqrt{6}} \end{bmatrix} = \mathbf{PDP}^\top$$

$$\mathbf{V} = \mathbf{P} = \begin{bmatrix} \frac{5}{\sqrt{30}} & 0 & \frac{-1}{\sqrt{6}} \\ \frac{-2}{\sqrt{30}} & \frac{1}{\sqrt{5}} & \frac{-2}{\sqrt{6}} \\ \frac{1}{\sqrt{30}} & \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{6}} \end{bmatrix}$$

$$\det\left(\begin{pmatrix} 5-x & -2 & 1 \\ -2 & 1-x & 0 \\ 1 & 0 & 1-x \end{pmatrix}\right)$$

$$-x^3 + 7x^2 - 6x = 0$$

$$\mathbf{\Sigma} = \begin{bmatrix} \sqrt{6} & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

Tekil değer ayrıştırması

Örnek:

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix}$$

$$\mathbf{V} = \mathbf{P} = \begin{bmatrix} \frac{5}{\sqrt{30}} & 0 & \frac{-1}{\sqrt{6}} \\ \frac{-2}{\sqrt{30}} & \frac{1}{\sqrt{5}} & \frac{-2}{\sqrt{6}} \\ \frac{1}{\sqrt{30}} & \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{6}} \end{bmatrix}$$

$$\mathbf{u}_1 = \frac{1}{\sigma_1} \mathbf{A} \mathbf{v}_1 = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix} \begin{bmatrix} \frac{5}{\sqrt{30}} \\ \frac{-2}{\sqrt{30}} \\ \frac{1}{\sqrt{30}} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{5}} \\ -\frac{2}{\sqrt{5}} \end{bmatrix}$$

$$\mathbf{u}_2 = \frac{1}{\sigma_2} \mathbf{A} \mathbf{v}_2 = \frac{1}{1} \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0 \\ \frac{1}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} \end{bmatrix} = \begin{bmatrix} \frac{2}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} \end{bmatrix},$$

$$\mathbf{U} = [\mathbf{u}_1, \mathbf{u}_2] = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 & 2 \\ -2 & 1 \end{bmatrix}$$



Tekil değer ayrıştırması

- SVD ve özayrıştırmanın farkları
 - SVD bütün reel matrisler için var, öz ayrıştırma ise sadece kare matrisler için tanımlı. O da sadece eğer özvektörlerden ilgili uzay için bir baz oluşturabilirsek mümkün.
 - İki ayrıştırmada da operasyon (tanım uzayında) baz değişimi, baz vektörlerinin ayrı ayrı ölçeklendirilmesi ve (değer uzayında) baz değişimi şeklinde. Ama SVD'de tanım ve değer uzayı'nın boyutları farklı (olabilir).
 - Özayrıştırmada \mathbf{P} matrisinin içerisindeki vektörler birbirine ortogonal olmak zorunda değil. Bu da baz değişimi işleminin ve \mathbf{A} 'nın yarattığı dönüşümün rotasyon ve ölçekleme gibi parçalara ayrılmasını engelliyor.



Tekil değer ayrıştırması

- SVD ve özayrıştırmanın farkları
 - Özayrıştırma \mathbf{P} ve \mathbf{P} 'nin tersi kullanılırken SVD'de \mathbf{U} ve \mathbf{V} matrisleri birbirinin tersi olmak zorunda değil.
 - SVD'de diagonal matris değerleri reel ve sıfırdan büyük eşit. Özayrıştırma böyle bir garanti yok.
 - Yine de bunlar birbirleri ile alakalı ayrıştırmalar:
 - \mathbf{A} matrisinin sol tekil vektörleri $\mathbf{A}\mathbf{A}^T$ matrisinin özvektörleridir.
 - \mathbf{A} matrisinin sağ tekil vektörleri $\mathbf{A}^T\mathbf{A}$ matrisinin özvektörleridir.
 - \mathbf{A} matrisinin sıfırdan farklı tekil değerleri $\mathbf{A}^T\mathbf{A}$ matrisinin (dolayısıyla $\mathbf{A}\mathbf{A}^T$ matrisinin) özdeğerlerinin kareköklerine eşittir.

Tekil değer ayrıştırması

$$\begin{array}{c}
 \begin{array}{c} \text{Star Wars} \\ \text{Blade Runner} \\ \text{Amelie} \\ \text{Delicatessen} \end{array}
 \begin{bmatrix}
 5 & 4 & 1 \\
 5 & 5 & 0 \\
 0 & 0 & 5 \\
 1 & 0 & 4
 \end{bmatrix}
 =
 \begin{bmatrix}
 -0.6710 & 0.0236 & 0.4647 & -0.5774 \\
 -0.7197 & 0.2054 & -0.4759 & 0.4619 \\
 -0.0939 & -0.7705 & -0.5268 & -0.3464 \\
 -0.1515 & -0.6030 & 0.5293 & -0.5774
 \end{bmatrix}
 \end{array}$$

$$\begin{bmatrix}
 9.6438 & 0 & 0 \\
 0 & 6.3639 & 0 \\
 0 & 0 & 0.7056 \\
 0 & 0 & 0
 \end{bmatrix}$$

$$\begin{array}{c}
 \text{Bilimkurgu sever} \\
 \text{Sanat filmi sever} \\
 ?
 \end{array}
 \begin{bmatrix}
 -0.7367 & -0.6515 & -0.1811 \\
 0.0852 & 0.1762 & -0.9807 \\
 0.6708 & -0.7379 & -0.0743
 \end{bmatrix}
 \begin{array}{c}
 \text{Ali} \\
 \text{Beatrix} \\
 \text{Chandra}
 \end{array}$$

Matris yaklaşımı

$$\begin{matrix} n \\ m \end{matrix} \mathbf{A} = \begin{matrix} m \\ m \end{matrix} \mathbf{U} \begin{matrix} n \\ m \end{matrix} \mathbf{\Sigma} \begin{matrix} n \\ n \end{matrix} \mathbf{V}^{\top}$$

$$\begin{matrix} m \times n \\ m \times r \end{matrix} = \begin{matrix} m \times r \\ r \times n \\ 0 \end{matrix} \begin{matrix} n \times n \end{matrix}$$


$$\mathbf{A} = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^{\top} = \sum_{i=1}^r \sigma_i \mathbf{A}_i$$

Matris yaklaşımı


$$\mathbf{A} \in \mathbb{R}^{1432 \times 1910}$$



(a) Original image \mathbf{A} .



(b) \mathbf{A}_1 , $\sigma_1 \approx 228,052$.




(c) \mathbf{A}_2 , $\sigma_2 \approx 40,647$.

$$\mathbf{A}_i := \mathbf{u}_i \mathbf{v}_i^\top$$


$$\mathbf{u} = [1, 2, 3]^\top$$

$$\mathbf{v} = [5, 10, 15]^\top$$


5	10	15
10	20	30
15	30	45



(d) \mathbf{A}_3 , $\sigma_3 \approx 26,125$.



(e) \mathbf{A}_4 , $\sigma_4 \approx 20,232$.



(f) \mathbf{A}_5 , $\sigma_5 \approx 15,436$.


Matris yaklaşımı

$$\mathbf{A} \in \mathbb{R}^{1432 \times 1910}$$


$$\begin{aligned}\hat{\mathbf{A}}(k) &:= \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^\top \\ &= \sum_{i=1}^k \sigma_i \mathbf{A}_i\end{aligned}$$



(a) Original image \mathbf{A} .



(b) Rank-1 approximation $\hat{\mathbf{A}}(1)$.



(c) Rank-2 approximation $\hat{\mathbf{A}}(2)$.



(d) Rank-3 approximation $\hat{\mathbf{A}}(3)$.



(e) Rank-4 approximation $\hat{\mathbf{A}}(4)$.



(f) Rank-5 approximation $\hat{\mathbf{A}}(5)$.

Matris yaklaşımı

$$\mathbf{A} \in \mathbb{R}^{1432 \times 1910}$$

$$\begin{aligned}\hat{\mathbf{A}}(k) &:= \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^\top \\ &= \sum_{i=1}^k \sigma_i \mathbf{A}_i\end{aligned}$$



(a) Original image \mathbf{A} .

$$1432 \times 1910 = 2,735,120$$



(f) Rank-5 approximation $\hat{\mathbf{A}}(5)$.

$$5 \times (1432 + 1910 + 1) = 16,715$$

(original boyutun sadece %0.6'sı)



Matris yaklaşımı

Matris normları:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$

$$\|A\|_2 = \sigma_{\max}(A)$$

$$\|A\|_{\infty} = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$$

$$\|A\|_F = \left(\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2 \right)^{\frac{1}{2}}$$



Matris yaklaşımı

Tanım: Bir $\mathbf{A} \in \mathbb{R}^{m \times n}$ matrisinin **spektral normu** bütün $\mathbf{x} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$ vektörleri üzerinden şu şekilde hesaplanır

$$\|\mathbf{A}\|_2 := \max_{\mathbf{x}} \frac{\|\mathbf{Ax}\|_2}{\|\mathbf{x}\|_2}$$

Teorem: Bir matrisin spektral normu en büyük tekil değerine eşittir.

Teorem (Eckart-Young): $\mathbf{A} \in \mathbb{R}^{m \times n}$ mertebesi r olan, $\mathbf{B} \in \mathbb{R}^{m \times n}$ ise mertebesi $k \leq r$, olan iki matris olsun. Mertebesi k olan yaklaşık matris $\hat{\mathbf{A}}(k) = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T$ için

$$\begin{aligned} \hat{\mathbf{A}}(k) &= \operatorname{argmin}_{\operatorname{rk}(\mathbf{B})=k} \|\mathbf{A} - \mathbf{B}\|_2, \\ \|\mathbf{A} - \hat{\mathbf{A}}(k)\|_2 &= \sigma_{k+1}. \end{aligned}$$

ifadesi doğrudur.

Matris yaklaşımı

	Ali	Beatrix	Chandra
Star Wars	5	4	1
Blade Runner	5	5	0
Amelie	0	0	5
Delicatessen	1	0	4

$$= \begin{bmatrix} -0.6710 & 0.0236 & 0.4647 & -0.5774 \\ -0.7197 & 0.2054 & -0.4759 & 0.4619 \\ -0.0939 & -0.7705 & -0.5268 & -0.3464 \\ -0.1515 & -0.6030 & 0.5293 & -0.5774 \end{bmatrix}$$

$$\begin{bmatrix} 9.6438 & 0 & 0 \\ 0 & 6.3639 & 0 \\ 0 & 0 & 0.7056 \\ 0 & 0 & 0 \end{bmatrix}$$

$$\begin{bmatrix} -0.7367 & -0.6515 & -0.1811 \\ 0.0852 & 0.1762 & -0.9807 \\ 0.6708 & -0.7379 & -0.0743 \end{bmatrix}$$

$$\mathbf{A}_1 = \mathbf{u}_1 \mathbf{v}_1^\top = \begin{bmatrix} -0.6710 \\ -0.7197 \\ -0.0939 \\ -0.1515 \end{bmatrix} \begin{bmatrix} -0.7367 & -0.6515 & -0.1811 \end{bmatrix} = \begin{bmatrix} 0.4943 & 0.4372 & 0.1215 \\ 0.5302 & 0.4689 & 0.1303 \\ 0.0692 & 0.0612 & 0.0170 \\ 0.1116 & 0.0987 & 0.0274 \end{bmatrix}$$

$$\hat{\mathbf{A}}(2) = \sigma_1 \mathbf{A}_1 + \sigma_2 \mathbf{A}_2 = \begin{bmatrix} 4.7801 & 4.2419 & 1.0244 \\ 5.2252 & 4.7522 & -0.0250 \\ 0.2493 & -0.2743 & 4.9724 \\ 0.7495 & 0.2756 & 4.0278 \end{bmatrix}$$



Uygulamalar

- Fotoğraf sıkıştırma
 - Bunun bir örneği yansılarda var.
- Eigenfaces
 - Farklı yüzlerden bir eğitim kümesi oluşturalım
 - SVD ile en dominant özvektörleri bulalım - bu verideki maksimum farkı yaratan doğrultuları verecektir.
 - En büyük m tane vektörü seçelim - bu bize yeni bir yüz uzayı tanımlayacak
 - Bütün veriyi bu uzaya eşleyelim
 - Yeni gelen bir yüz için en yakındaki yüzlere bakıp ona göre bir tahmin yapalım






Uygulamalar

- Kümeleme
 - Uzayda noktalar, ya da noktaların kenarlar ile bağlandığı bir çizge... Yakınlık ya da komşuluk matrisi oluşturulur: **A**
 - Noktaların derece matrisi hesaplanır: **D**
 - **L = A - D** şeklinde Laplasyen matris oluşturulur ve en büyük **k** özdeğeri hesaplanır
 - Bu özdeğerlere tekabül eden özvektörler ve k-means algoritması ile **k** sınıfa kümelendir.



$$\mathbf{L} = \begin{bmatrix} 2 & -1 & -1 & 0 \\ -1 & 3 & -1 & -1 \\ -1 & -1 & 2 & 0 \\ 0 & -1 & 0 & 1 \end{bmatrix}$$






Uygulamalar

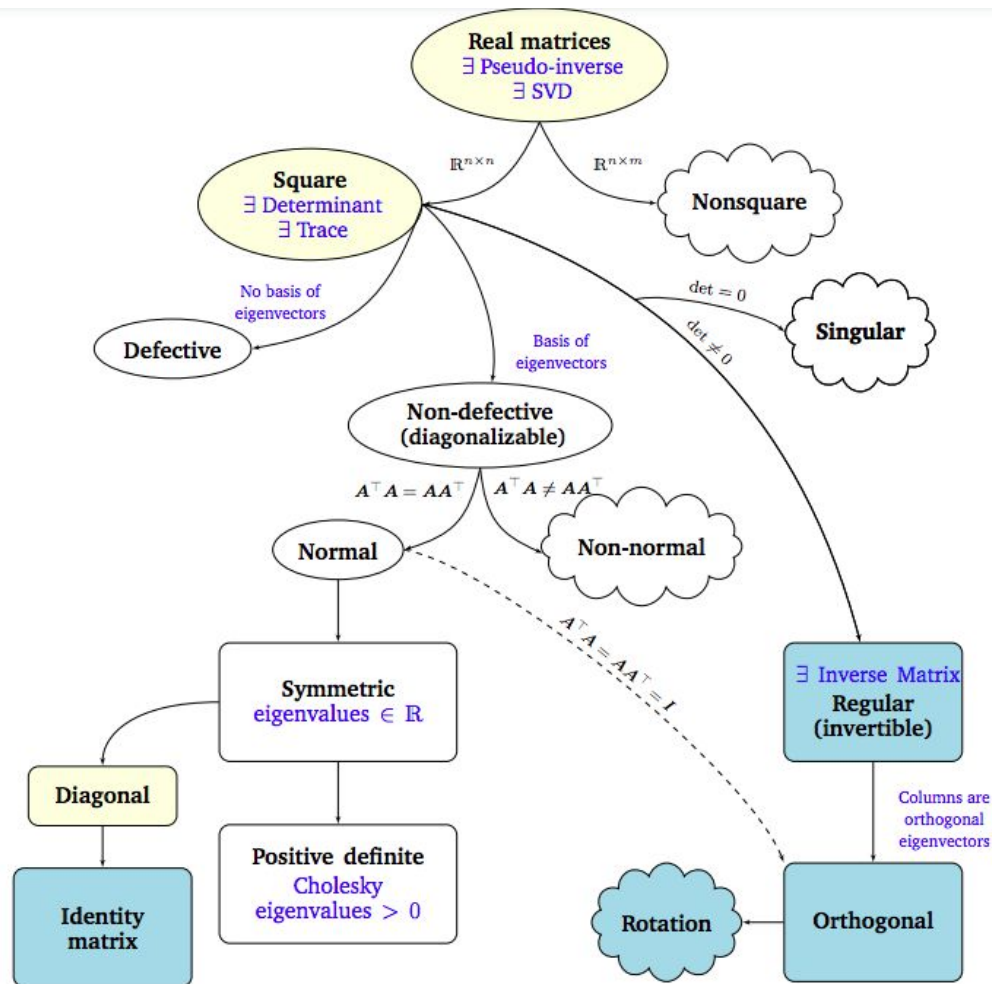
- Videolardaki arka planı bulma
 - Bir videoda ön plan, objelerin, insanların, araçların vs hareket ettiği kısımdır
 - Arka plan ise durağandır - üzerinde çok hareket olmaz
 - Videodan frameleri seçip bir bunların sütun olduğu bir matris oluşturalım. Burada görülen dalgalılar o piksel üzerinde hareket olduğunu gösterir.
 - Üzerinde hareket olmayan pikseller (satırlar) ise arka planın bir parçasıdır.
 - Dolayısıyla düşük mertebe bir yaklaşım bize arkaplanı verecektir.



LOW RANK BACKGROUND



FOREGROUND





Yararlı kaynaklar

Gilbert Strang: <https://www.youtube.com/playlist?list=PLUL4u3cNGP63oMNUHXqIUcrkS2PivhN3k>

3Blue1Brown: https://www.youtube.com/playlist?list=PLZHQObOWTQDPD3MizzM2xVFitgF8hE_ab