


SÜREKLİ ENİYİLEME

(CHAPTER 7)

Matematiksel Eniyileme Problemi



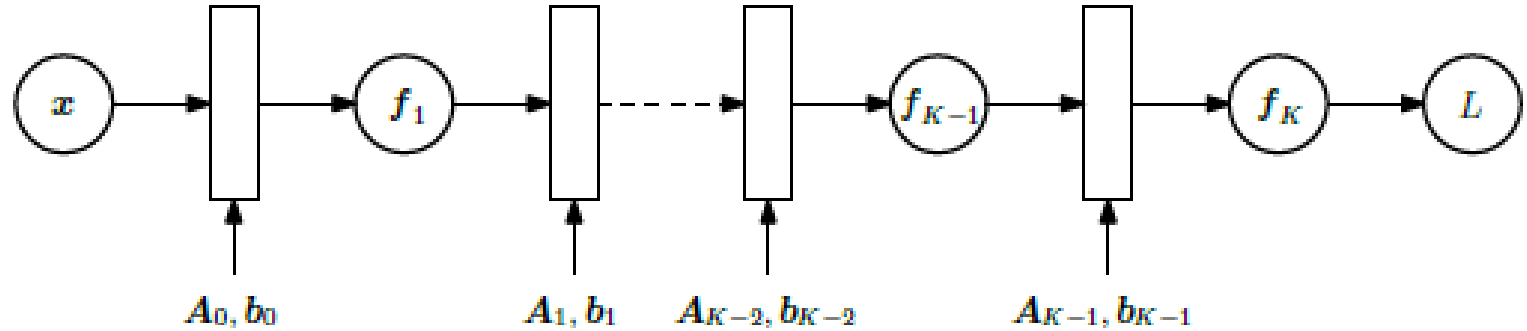
$$\begin{aligned} & \min_{\mathbf{x}} \quad f(\mathbf{x}) \\ & \text{subject to} \quad g_i(\mathbf{x}) \leq 0 \quad \text{for all} \quad i = 1, \dots, m. \end{aligned}$$

- Terminoloji
- Bu dersin kapsamı

Yapay Öğrenme için Eniyileme

- Yapay sinir ağı

$$\begin{aligned}x_{k+1} &= f_k(x_k) \\ f_k(x_k) &= \sigma_k(A_k x_k + b_k)\end{aligned}$$



$$y = (f_K \circ f_{K-1} \circ \cdots \circ f_1)(x) = f_K(f_{K-1}(\cdots(f_1(x))\cdots))$$

- Kayıp fonksiyonu $L(\theta)$, $\theta = \{A_0, b_0, \dots, A_{K-1}, b_{K-1}\}$

Yapay Öğrenme için Eniyileme

- Boyut İndirgeme (Chapter 10)
- Sınıflandırma (Chapter 12)

$$\begin{aligned} & \max_{b_1} b_1^T S b_1 \\ & \text{subject to } \|b_1\|^2 = 1. \end{aligned}$$

$$\begin{aligned} & \min_{w, b} \underbrace{\frac{1}{2} \|w\|^2}_{\text{margin}} \\ & \text{subject to } \underbrace{y_n (\langle w, x_n \rangle + b)}_{\text{data fitting}} \geq 1. \end{aligned}$$


Kritik Konular

Yöntem geliştirirken ya da seçerken

- Sürekli mi?
- Türevlenebilir mi?
- Dışbükey mi?
- Deterministik mi?
- Problemin özel bir yapısı var mı?
- Problem boyutu

$$\begin{array}{ll} \min_{\mathbf{x}} & f(\mathbf{x}) \\ \text{subject to} & g_i(\mathbf{x}) \leq 0 \quad \text{for all } i = 1, \dots, m. \end{array}$$

Eniyileme Probleminin Çözümü



- Gerek koşul
- Yeter koşul
- Yerel çözüm
- Global çözüm

Eniyileme Probleminin Çözümü

$$\begin{array}{ll} \min_{\mathbf{x}} & f(\mathbf{x}) \\ \text{subject to} & g_i(\mathbf{x}) \leq 0 \quad \text{for all } i = 1, \dots, m. \end{array}$$


- Bir çözüm bulmak her zaman mümkün mü?
- Teori: Amaç fonksiyonu alttan sınırlı, olurlu çözümler kümesi boş değil ve kapalıysa
- Pratikte çoğu zaman yaklaşık çözümler hesaplarız

Gradyan Algoritması

$$\min_{\mathbf{x}} f(\mathbf{x})$$

$$\mathbf{x}_{i+1} = \mathbf{x}_i - \gamma_i ((\nabla f)(\mathbf{x}_i))^{\top}$$

- Analitik çözüm nadiren mümkün
- En hızlı düşüş
- Adım boyu




Gradyan Algoritması

$$f\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \frac{1}{2} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^\top \begin{bmatrix} 2 & 1 \\ 1 & 20 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - \begin{bmatrix} 5 \\ 3 \end{bmatrix}^\top \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$\nabla f\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^\top \begin{bmatrix} 2 & 1 \\ 1 & 20 \end{bmatrix} - \begin{bmatrix} 5 \\ 3 \end{bmatrix}^\top$$

- Yakınsama hızı
- Hesse matrisinin sağlamlık sayısı



Gradyan Algoritması

- Momentum

$$\mathbf{x}_{i+1} = \mathbf{x}_i - \gamma_i ((\nabla f)(\mathbf{x}_i))^{\top} + \alpha \Delta \mathbf{x}_i \quad (7.11)$$

$$\Delta \mathbf{x}_i = \mathbf{x}_i - \mathbf{x}_{i-1} = \alpha \Delta \mathbf{x}_{i-1} - \gamma_{i-1} ((\nabla f)(\mathbf{x}_{i-1}))^{\top}, \quad (7.12)$$

- Hızlandırma
- Newtonumsu (Değişken-metrik)

Stokastik Gradyan Algoritması

- Sistematik hata içermeyen yaklaşık gradyan

- Ampirik risk (SAA)

$$L(\theta) = \sum_{n=1}^N L_n(\theta),$$


- En büyük olabilirlik kestirimi

$$L(\theta) = - \sum_{n=1}^N \log p(y_n | x_n, \theta),$$

- Doğrudan beklenen kayıp fonksiyonuna uygulama (SA)

- Varyans düşürme, ölçekleme, momentum, ...

Kısıtlı Eniyileme Problemi



$$\begin{aligned} \min_{\mathbf{x}} \quad & f(\mathbf{x}) \\ \text{subject to} \quad & g_i(\mathbf{x}) \leq 0 \quad \text{for all } i = 1, \dots, m. \end{aligned}$$

- Aktif kısıt
- Olurlu yönler konisi
- Kısıtlı durumda gerek koşul

Lagrange Çarpanları

$$\begin{aligned}\mathcal{L}(x, \lambda) &= f(x) + \sum_{i=1}^m \lambda_i g_i(x) \\ &= f(x) + \lambda^\top g(x),\end{aligned}$$

$$J(x) = f(x) + \sum_{i=1}^m 1(g_i(x)), \quad 1(z) = \begin{cases} 0 & \text{if } z \leq 0 \\ \infty & \text{otherwise} \end{cases}.$$

$$J(x) = \max_{\lambda \geq 0} \mathcal{L}(x, \lambda).$$

- Amaç fonksiyonunun kısıtlara duyarlılığı
- Aktif olmayan kısıtlara karşılık gelen çarpanlar
- Çarpanların sonlu değer alması

Lagrange Eşiz

$$\mathcal{D}(\lambda) = \min_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda).$$

$$\begin{aligned} & \max_{\lambda \in \mathbb{R}^m} \mathcal{D}(\lambda) \\ & \text{subject to } \lambda \geq 0, \end{aligned}$$

$$J(x) = f(x) + \sum_{i=1}^m 1(g_i(x)), \quad 1(z) = \begin{cases} 0 & \text{if } z \leq 0 \\ \infty & \text{otherwise} \end{cases}.$$

$$J(x) = \max_{\lambda \geq 0} \mathcal{L}(x, \lambda).$$

$$\min_{x \in \mathbb{R}^d} \max_{\lambda \geq 0} \mathcal{L}(x, \lambda) \geq \max_{\lambda \geq 0} \min_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda).$$

- Optimallik açıklığı
- Güçlü düalite özelliği

Dışbükey Eniyileme

- Dışbükey küme

Figure 7.5 Example of a convex set.






Figure 7.6 Example of a nonconvex set.



- Dışbükey fonksiyon

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y), \quad 0 \leq \theta \leq 1.$$


$$f(y) \geq f(x) + \nabla_x f(x)^\top (y - x).$$



Doğrusal Program

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{subject to} \quad & Ax \leq b, \end{aligned}$$

$$\begin{aligned} \max_{\lambda \in \mathbb{R}^m} \quad & -b^\top \lambda \\ \text{subject to} \quad & c + A^\top \lambda = 0 \\ & \lambda \geq 0. \end{aligned}$$




Karesel Program

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & \frac{1}{2} x^\top Q x + c^\top x \\ \text{subject to} \quad & A x \leq b, \end{aligned}$$

$$\begin{aligned} \max_{\lambda \in \mathbb{R}^m} \quad & -\frac{1}{2} (c + A^\top \lambda)^\top Q^{-1} (c + A^\top \lambda) - \lambda^\top b \\ \text{subject to} \quad & \lambda \geq 0. \end{aligned}$$

- SVM



Dışbükey Eşlenik

$$f^*(s) = \sup_{\mathbf{x} \in \mathbb{R}^D} (\langle s, \mathbf{x} \rangle - f(\mathbf{x})) .$$

- Örnek

$$f(y) = \frac{\lambda}{2} y^\top K^{-1} y$$

- Dual problem türetimi

$$\min_{\mathbf{x}} f(A\mathbf{x}) + g(\mathbf{x}) = \max_{\mathbf{u}} -f^*(\mathbf{u}) - g^*(-A^\top \mathbf{u}) .$$